ESTUDIANTE 1 · PROBLEMA Y MODELO

Detección de correos de phishing con LSTM

Aplicaciones de Inteligencia Artificial · INACAP · Segunda evaluación 2026

[Nombre estudiante 1]

1 El problema

¿Qué problema queremos resolver y por qué importa?

Qué es el phishing

Un correo que imita a un banco, a un despacho o al soporte TI para que la persona entregue su clave, sus datos o haga un pago. Llega mezclado con correos legítimos.

Lo que resolvemos

Clasificar cada correo entrante como seguro o fraudulento a partir de su texto, con una probabilidad de fraude. Lo sospechoso va a cuarentena antes de llegar a la bandeja.

A quién afecta

- Trabajadores o estudiantes que reciben correos.
- El área de TI, que revisa reportes a mano.
- La organización y las personas cuyos datos administra.

Si no se hace nada

- Basta con que **una** persona caiga para comprometer una cuenta.
- Pagos falsos, filtración de datos, horas de TI.
- Ley 21.663 (reportar incidentes a la ANCI) y Ley 21.719 (datos personales).

Por qué IA

- Las reglas fijas se esquivan cambiando una palabra.
- Un modelo aprende patrones de miles de ejemplos: urgencia, amenazas, pedidos de clave.
- Entrega una probabilidad, no solo sí o no.

Riesgos y beneficios

- **Falso negativo**: un fraude que pasa. Es el error más grave.
- Falsas alarmas, ataques que cambian, privacidad.
- Beneficio: menos fraudes en la bandeja y menos revisión manual.

Datos: Kaggle "Phishing Email Detection" · aprendizaje supervisado

18.650
correos etiquetados



Cada correo trae su respuesta correcta. Limitaciones: están en inglés, mezclan phishing con spam y 1 de cada 5 seguros viene de una sola empresa (Enron).

2 El modelo: Embedding + LSTM

¿Por qué este modelo es adecuado y cómo funciona? · Clasificación binaria de texto (secuencias)

Correo texto limpio, enlaces = "enlaceweb" › **200 números** vocabulario de 20.000 palabras › **Embedding** cada palabra pasa a un vector de 64 valores › **LSTM 64** lee en orden y resume el correo › **Dropout 0,5** apaga la mitad al entrenar › **Dense + sigmoide** probabilidad entre 0 y 1

1.313.089 parámetros: Embedding 1.280.000 · LSTM 33.024 · Dense 65. Basado en el ejemplo de noticias falsas visto en clases, con una LSTM en vez de dos.

Por qué una LSTM

- Un correo es una **secuencia**: el orden de las palabras cambia el sentido.
- Lee palabra por palabra y guarda una memoria con tres compuertas: **olvido** (qué borrar) · **entrada** (qué guardar) · **salida** (qué entregar).
- Así relaciona palabras lejanas, cosa que una RNN simple pierde.

Marco teórico

- **Neurona**: suma entradas por **pesos**, más un **sesgo**, y aplica una activación.
- **Activaciones**: sigmoide en la salida; sigmoide y tanh en las compuertas.
- **Propagación hacia adelante**: el correo pasa por las capas y sale p.
- **Sobreajuste**: memorizar el entrenamiento. Se frena con Dropout, validación separada y parada temprana.

Cómo aprende

1 · Predice sale una probabilidad, ej. 0,98 › **2 · Mide el error** entropía cruzada binaria: castiga equivocarse con seguridad › **3 · Retropropagación** cuánto aportó cada peso al error › **4 · Adam** descenso del gradiente: ajusta cada peso un poco › **Repite** lotes de 32 · hasta 6 épocas · early stopping

Métricas que vamos a mirar

Exactitud: % de aciertos. No basta sola.

Recall de fraude: de los fraudes, cuántos detecta. La más importante.

Precisión: de lo marcado como fraude, cuánto lo era.

AUC: separación de clases, 1 perfecto y 0,5 azar.

Salida esperada: una probabilidad de fraude por correo. Sobre 0,5 se marca fraudulento; la organización puede mover ese umbral.
Honestidad: una regresión logística empata en exactitud (0,967); la LSTM se eligió porque considera el orden.