ESTUDIANTE 2 · IMPLEMENTACIÓN Y RESULTADOS

Detección de correos de phishing con LSTM

Aplicaciones de Inteligencia Artificial · INACAP · Segunda evaluación 2026

[Nombre estudiante 2]

1 Implementación en vivo en Google Colab

Python · TensorFlow / Keras · scikit-learn · GPU T4 · 17 pasos, uno por celda

Entorno Colab, librerías, kagglehub › **Datos** 18.650 correos de Kaggle › **Limpieza** texto limpio y sin duplicados › **Números** vocabulario de 20.000, 200 por correo › **Modelo** Embedding + LSTM › **Entrenar** hasta 6 épocas › **Evaluar y probar** métricas y correos nuevos

Limpieza del texto: `limpiar()`

- Minúsculas, sin HTML, solo letras.
- Cada enlace se reemplaza por la palabra `enlaceweb`.
- Se quitan correos vacíos y duplicados: **18.650 → 17.103**.

Atajo que encontramos: Enron

"enron" aparece en el **20,3%** de los seguros y en el **0%** de los fraudes. El modelo aprendería "si dice enron, es seguro". Se borran `enron, vince, kaminski, hou, ect` para que aprenda del contenido.

División de los 17.103 correos (estratificada, random_state = 42)

Entrenamiento 11.629	Validación 2.053	Prueba 3.421

El vocabulario se arma solo con entrenamiento. La validación decide cuándo parar. La prueba se usa una sola vez, al final.

```
# Paso 9: arquitectura
modelo = keras.Sequential([
  keras.Input(shape=(LARGO,)),
  layers.Embedding(VOCABULARIO, 64, mask_zero=True),
  layers.LSTM(64),
  layers.Dropout(0.5),
  layers.Dense(1, activation='sigmoid')
])
# Paso 10: entrenamiento
modelo.compile(optimizer='adam',
  loss='binary_crossentropy',
  metrics=['accuracy', Recall, Precision])
# Paso 11: early stopping
modelo.fit(X_ent_num, y_ent, epochs=6,
  batch_size=32, validation_data=(X_val_num, y_val),
  callbacks=[EarlyStopping(patience=2)])
```

Qué hace cada instrucción

- **mask_zero**: ignora el relleno de ceros.
- **LSTM(64)**: lee el correo en orden y lo resume en 64 valores.
- **Dropout(0.5)**: apaga la mitad al entrenar para no memorizar.
- **sigmoid**: entrega la probabilidad de fraude.
- **binary_crossentropy + adam**: mide el error y ajusta los pesos.
- **EarlyStopping**: si la validación no mejora en 2 épocas, para y recupera los mejores pesos.

2 Resultados en 3.421 correos de prueba

0,967	0,945	0,967	0,991
Exactitud	Recall de fraude	Precisión de fraude	AUC

Matriz de confusión (LSTM)

	Predice seguro	Predice fraude
Seguro (2.132)	2.091	41 falsas alarmas
Fraude (1.289)	**71 se escapan**	**1.218 detectados**

LSTM contra regresión logística

	LSTM	Reg. logística
Exactitud	0,967	0,967
Recall de fraude	0,945	0,940
AUC	0,991	0,995

Casi iguales: aquí las palabras sueltas ya separan casi todo.

Prueba con 4 correos nuevos, escritos por nosotros (paso 14)

Correo	Real	Modelo	P(fraude)	
Banco: cuenta suspendida, verificar en 24 horas	Fraude	Fraudulento	99,1%	**Acierta**
Paquete: pagar $2,99 para reenviar	Fraude	Fraudulento	97,8%	**Acierta**
Soporte TI: confirmar cuenta de estudiante	Fraude	Seguro	4,1%	**Se escapa**
Coordinación: aviso de presentaciones	Seguro	Seguro	0,4%	**Acierta**

El fraude de Soporte TI está bien escrito, sin urgencia ni amenazas, y usa vocabulario académico que en el dataset aparece casi solo en correos seguros.

Conclusión: responde **parcialmente** al problema. Detecta 1.218 de 1.289 fraudes (94,5%) con pocas falsas alarmas, pero se escapan los fraudes bien redactados. **Mejoras:** datos más variados y en español, leer más de 200 palabras y ajustar el umbral.