ESTUDIANTE 1 · PROBLEMA Y MODELO

Detección de correos de phishing con LSTM

Aplicaciones de Inteligencia Artificial · INACAP · Segunda evaluación 2026

[Nombre estudiante 1]

1 El problema

¿Qué problema queremos resolver y por qué importa?

Qué es el phishing

Un correo que imita a un banco, a un despacho o al soporte TI para que la persona entregue su clave, sus datos o haga un pago. Llega mezclado con correos legítimos.

Lo que resolvemos

Clasificar cada correo entrante como seguro o fraudulento a partir de su texto, con una probabilidad de fraude. Lo sospechoso va a cuarentena antes de llegar a la bandeja.

A quién afecta

- Trabajadores o estudiantes que reciben correos.
- El área de TI, que revisa reportes a mano.
- La organización y las personas cuyos datos administra.

Si no se hace nada

- Basta con que **una** persona caiga para comprometer una cuenta.
- Pagos falsos, filtración de datos, horas de TI.
- Ley 21.663 (reportar incidentes a la ANCI) y Ley 21.719 (datos personales).

Por qué IA

- Las reglas fijas se esquivan cambiando una palabra.
- Un modelo aprende patrones de miles de ejemplos: urgencia, amenazas, pedidos de clave.
- Entrega una probabilidad, no solo sí o no.

Riesgos y beneficios

- **Falso negativo**: un fraude que pasa. Es el error más grave.
- Falsas alarmas, ataques que cambian, privacidad.
- Beneficio: menos fraudes en la bandeja y menos revisión manual.

Datos: Kaggle "Phishing Email Detection" · aprendizaje supervisado

18.650
correos etiquetados

11.322 seguros (61%) | **7.328 phishing (39%)**

Cada correo trae su respuesta correcta. Limitaciones: están en inglés, mezclan phishing con spam y 1 de cada 5 seguros viene de una sola empresa (Enron).

2 El modelo: Embedding + LSTM

¿Por qué este modelo es adecuado y cómo funciona? · Clasificación binaria de texto (secuencias)

Correo texto limpio, enlaces = "enlaceweb" › **200 números** vocabulario de 20.000 palabras › **Embedding** cada palabra pasa a un vector de 64 valores › **LSTM 64** lee en orden y resume el correo › **Dropout 0,5** apaga la mitad al entrenar › **Dense + sigmoide** probabilidad entre 0 y 1

1.313.089 parámetros: Embedding 1.280.000 · LSTM 33.024 · Dense 65. Basado en el ejemplo de noticias falsas visto en clases, con una LSTM en vez de dos.

Por qué una LSTM

- Un correo es una **secuencia**: el orden de las palabras cambia el sentido.
- Lee palabra por palabra y guarda una memoria con tres compuertas: **olvido** (qué borrar) · **entrada** (qué guardar) · **salida** (qué entregar).
- Así relaciona palabras lejanas, cosa que una RNN simple pierde.

Marco teórico

- **Neurona**: suma entradas por **pesos**, más un **sesgo**, y aplica una activación.
- **Activaciones**: sigmoide en la salida; sigmoide y tanh en las compuertas.
- **Propagación hacia adelante**: el correo pasa por las capas y sale p.
- **Sobreajuste**: memorizar el entrenamiento. Se frena con Dropout, validación separada y parada temprana.

Cómo aprende

1 · Predice sale una probabilidad, ej. 0,98 › **2 · Mide el error** entropía cruzada binaria: castiga equivocarse con seguridad › **3 · Retropropagación** cuánto aportó cada peso al error › **4 · Adam** descenso del gradiente: ajusta cada peso un poco › **Repite** lotes de 32 · hasta 6 épocas · early stopping

Métricas que vamos a mirar

Exactitud: % de aciertos. No basta sola.

Recall de fraude: de los fraudes, cuántos detecta. La más importante.

Precisión: de lo marcado como fraude, cuánto lo era.

AUC: separación de clases, 1 perfecto y 0,5 azar.

Salida esperada: una probabilidad de fraude por correo. Sobre 0,5 se marca fraudulento; la organización puede mover ese umbral.
Honestidad: una regresión logística empata en exactitud (0,967); la LSTM se eligió porque considera el orden.

ESTUDIANTE 2 · IMPLEMENTACIÓN Y RESULTADOS

Detección de correos de phishing con LSTM

Aplicaciones de Inteligencia Artificial · INACAP · Segunda evaluación 2026

[Nombre estudiante 2]

1 Implementación en vivo en Google Colab

Python · TensorFlow / Keras · scikit-learn · 17 pasos, uno por celda

Entorno Colab, librerías, kagglehub › **Datos** 18.650 correos de Kaggle › **Limpieza** texto limpio y sin duplicados › **Números** vocabulario de 20.000, 200 por correo › **Modelo** Embedding + LSTM › **Entrenar** hasta 6 épocas › **Evaluar y probar** métricas y correos nuevos

Limpieza del texto: `limpiar()`

- Minúsculas, sin HTML, solo letras.
- Cada enlace se reemplaza por la palabra `enlaceweb`.
- Se quitan correos vacíos y duplicados: **18.650 → 17.103**.

Atajo que encontramos: Enron

"enron" aparece en el **20,3%** de los seguros y en el **0%** de los fraudes. El modelo aprendería "si dice enron, es seguro". Se borran `enron, vince, kaminski, hou, ect` para que aprenda del contenido.

División de los 17.103 correos (estratificada, random_state = 42)

Entrenamiento 11.629	Validación 2.053	Prueba 3.421

El vocabulario se arma solo con entrenamiento. La validación decide cuándo parar. La prueba se usa una sola vez, al final.

```
# Paso 9: arquitectura
modelo = keras.Sequential([
  keras.Input(shape=(LARGO,)),
  layers.Embedding(VOCABULARIO, 64, mask_zero=True),
  layers.LSTM(64),
  layers.Dropout(0.5),
  layers.Dense(1, activation='sigmoid')
])
# Paso 10: entrenamiento
modelo.compile(optimizer='adam',
  loss='binary_crossentropy',
  metrics=['accuracy', Recall, Precision])
# Paso 11: early stopping
modelo.fit(X_ent_num, y_ent, epochs=6,
  batch_size=32, validation_data=(X_val_num, y_val),
  callbacks=[EarlyStopping(patience=2)])
```

Qué hace cada instrucción

- **mask_zero**: ignora el relleno de ceros.
- **LSTM(64)**: lee el correo en orden y lo resume en 64 valores.
- **Dropout(0.5)**: apaga la mitad al entrenar para no memorizar.
- **sigmoid**: entrega la probabilidad de fraude.
- **binary_crossentropy + adam**: mide el error y ajusta los pesos.
- **EarlyStopping**: si la validación no mejora en 2 épocas, para y recupera los mejores pesos.

2 Resultados en 3.421 correos de prueba

0,967	0,945	0,967	0,991
Exactitud	Recall de fraude	Precisión de fraude	AUC

Matriz de confusión (LSTM)

	Predice seguro	Predice fraude
Seguro (2.132)	2.091	41 falsas alarmas
Fraude (1.289)	**71 se escapan**	**1.218 detectados**

LSTM contra regresión logística

	LSTM	Reg. logística
Exactitud	0,967	0,967
Recall de fraude	0,945	0,940
AUC	0,991	0,995

Casi iguales: aquí las palabras sueltas ya separan casi todo.

Prueba con 4 correos nuevos, escritos por nosotros (paso 14)

Correo	Real	Modelo	P(fraude)	
Banco: cuenta suspendida, verificar en 24 horas	Fraude	Fraudulento	99,1%	**Acierta**
Paquete: pagar $2,99 para reenviar	Fraude	Fraudulento	97,8%	**Acierta**
Soporte TI: confirmar cuenta de estudiante	Fraude	Seguro	4,1%	**Se escapa**
Coordinación: aviso de presentaciones	Seguro	Seguro	0,4%	**Acierta**

El fraude de Soporte TI está bien escrito, sin urgencia ni amenazas, y usa vocabulario académico que en el dataset aparece casi solo en correos seguros.

Conclusión: responde **parcialmente** al problema. Detecta 1.218 de 1.289 fraudes (94,5%) con pocas falsas alarmas, pero se escapan los fraudes bien redactados. **Mejoras:** datos más variados y en español, leer más de 200 palabras y ajustar el umbral.