Detección de correos fraudulentos con una red LSTM



Aplicaciones de Inteligencia Artificial
Segunda evaluación · Primavera 2026

Estudiante 1 · Problema y modelo · [Nombre estudiante 1]

Estudiante 2 · Implementación en vivo · [Nombre estudiante 2]

¿Qué es el phishing?

Bank Security Department

URGENT: Your Bank Account Will Be Suspended

Dear Customer, We have detected unusual activity on your bank account.

To prevent your account from being **permanently suspended**, (2)

you must **verify your personal information** (4)

within the next 24 hours. (1)

Please confirm your identity using the following link:

https://secure-bank-validation.invalid/confirm (3)

Sincerely, Bank Security Department

Correo escrito para la prueba del proyecto; el dominio .invalid no existe.

1. **Urgencia**
2. **Amenaza**
3. **Enlace falso**
4. **Pide datos**

El problema que queremos resolver

Clasificar cada correo entrante como **seguro** o **fraudulento** a partir de su texto, y estimar qué tan probable es que sea fraude



Filtro de apoyo con revisión humana: lo sospechoso no se borra

¿A quién afecta y qué pasa si no hacemos nada?

Afectados

- Personas que reciben correos
- Área de TI
- La organización
- Clientes y sus datos

Si no hacemos nada

Una persona cae → Cuenta comprometida → Robo de datos o dinero → Ataques a otros desde adentro

Marco legal

- Ley 21.663 · Marco de Ciberseguridad
- Ley 21.719 · Protección de datos personales

Cifras en Chile

22% de los delitos ingresados en 2025: uso malicioso de tarjetas o claves y estafas

3.258 instituciones inscritas al cierre de 2025 para reportar incidentes a la ANCI

Fuentes: Fiscalía de Chile, 17 de agosto de 2026 (cifras de 2025; menciona el phishing entre las variantes de este fraude). ANCI, «ANCI presenta su primer balance anual», 2 de enero de 2026.

Los datos para estudiar el problema

18.650 correos

Kaggle · Phishing Email Detection (dataset público)

11.322 seguros

7.328 fraudulentos



Aprendizaje supervisado: cada correo trae su etiqueta — seguro — fraudulento

Limitaciones

- En inglés
- Phishing mezclado con spam
- 1 de cada 5 correos seguros menciona a Enron

¿Por qué usar Inteligencia Artificial?

Reglas fijas

- Lista de palabras prohibidas
- Filtro por remitente

El atacante cambia una palabra y pasa

Modelo que aprende

- Aprende de miles de ejemplos
- Reconoce patrones: urgencia, amenazas, pedidos de clave

Entrega una probabilidad

Oportunidades, beneficios y riesgos

Oportunidades

- Filtro de apoyo para TI
- Servicio para organizaciones sin equipo de seguridad: pymes, colegios, municipios
- Ejemplos reales para capacitar

Beneficios

- Menos fraudes en la bandeja
- Menos revisión manual
- Decisión medible

Riesgos

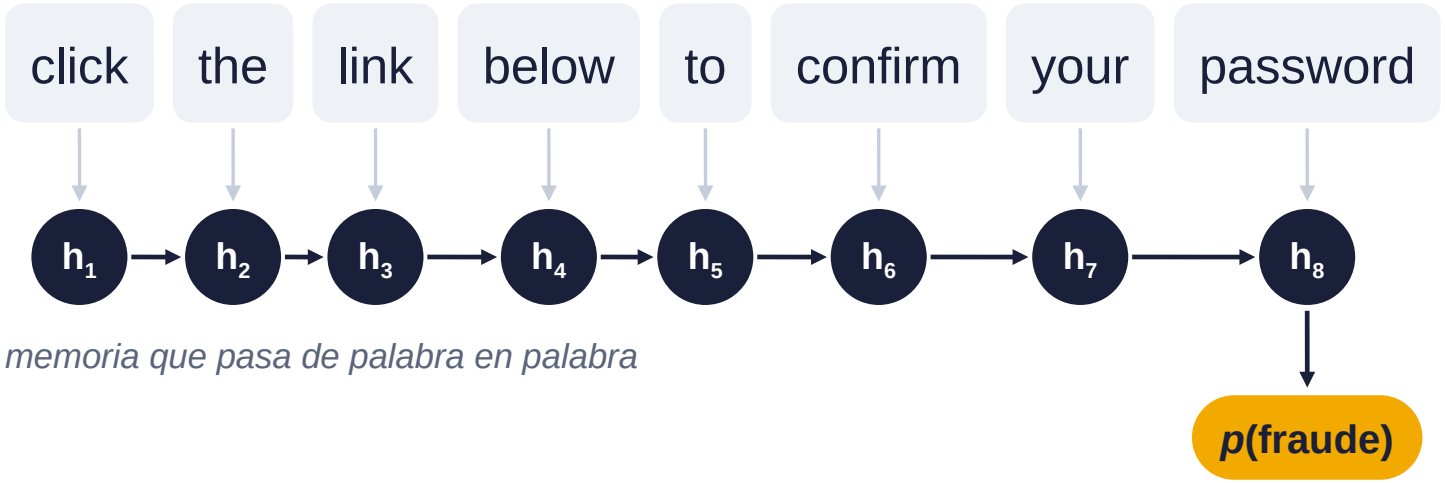
- Fraudes que se escapan
- Falsas alarmas
- Ataques que cambian
- Privacidad del contenido

¿Qué queremos resolver? Detener el phishing antes de que alguien caiga.

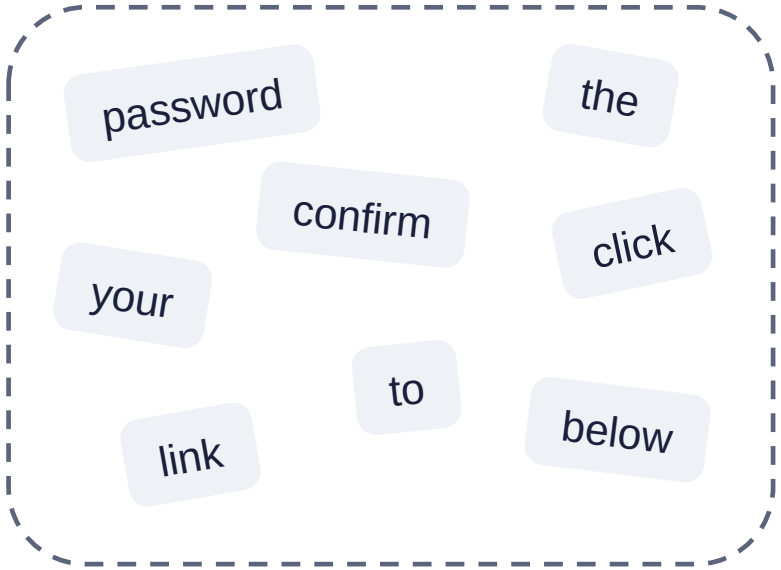
¿Por qué una red LSTM?

Clasificación binaria de texto **Aprendizaje supervisado**

Lee en orden y recuerda



memoria que pasa de palabra en palabra



Bolsa de palabras: sin orden

Así lee un modelo simple (paso 8)

Del texto a números

Correo

el texto tal como llega

→

Limpieza

minúsculas · sin HTML
enlaces → enlaceweb
solo letras

→

Vocabulario: 20.000 palabras

cada palabra
→ su número

→

200 números por correo

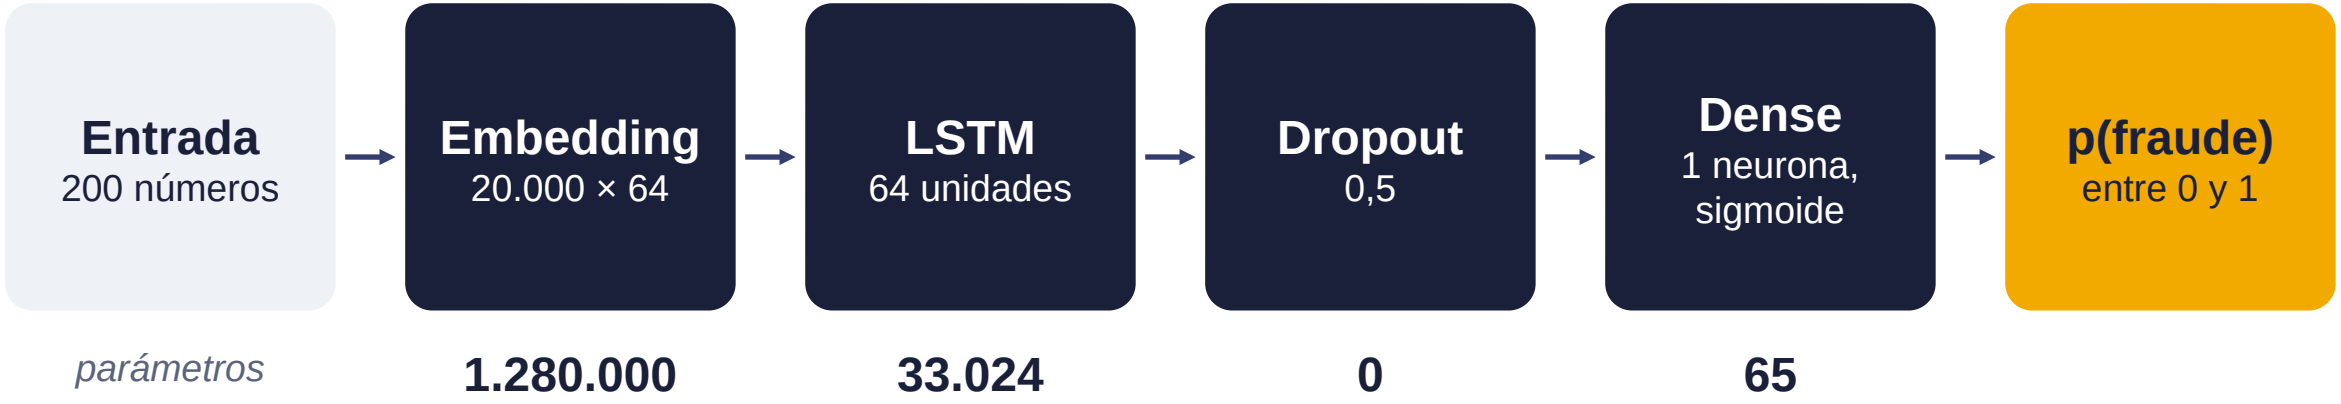
Mediana: 160 palabras

Ejemplo real (paso 7)

palabra	syntax	of	east	asian	languages	workshop	usc	workshop	on	synt…	…
número	**281**	**3**	**1056**	**1661**	**104**	**149**	**3129**	**149**	**12**	**281**	…

Más corto: se rellena con ceros · más largo: se corta

La arquitectura del modelo

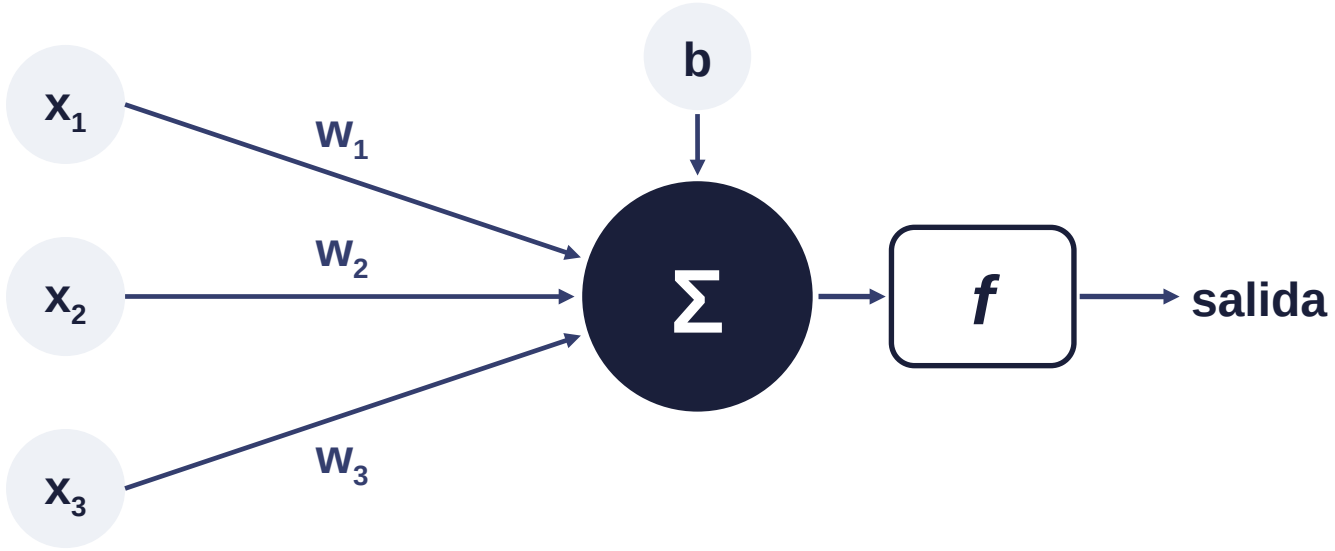


1.313.089 parámetros

LSTM y Dense: 3%

97% en el Embedding

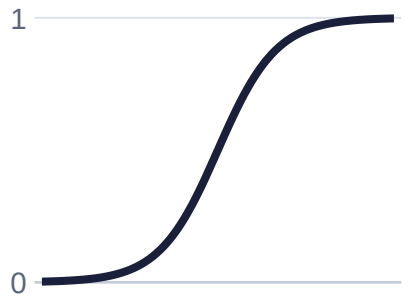
La neurona artificial



- **w** **Pesos:** cuánto importa cada entrada
- **b** **Sesgo:** desplaza el resultado
- ***f*** **Activación:** transforma la suma

$$\text{salida} = f(w_1 \cdot x_1 + w_2 \cdot x_2 + w_3 \cdot x_3 + b)$$

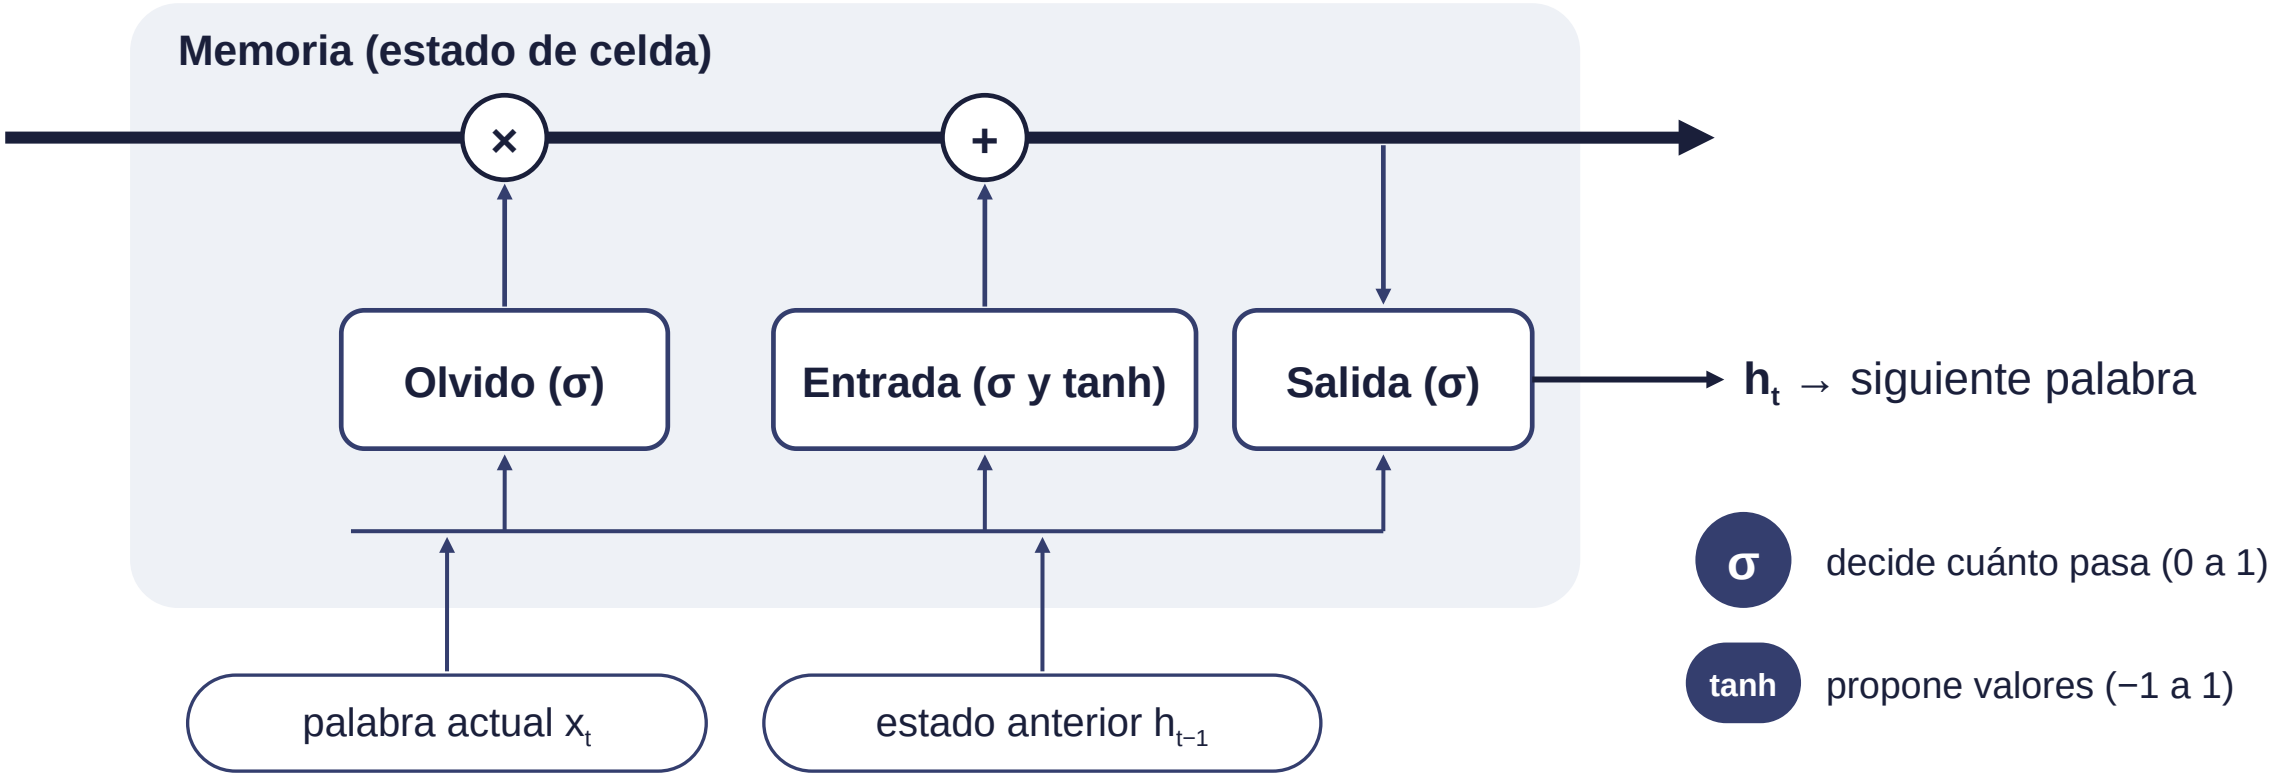
Sigmoide: de 0 a 1



tanh: de −1 a 1



Por dentro de la LSTM



Parámetros: **33.024 = 4 × (64 × 128 + 64)**

¿Cómo aprende?

1 Propagación hacia adelante

El correo entra y sale *p*

2 Pérdida: entropía cruzada binaria

$L = -[y \cdot \log(p) + (1-y) \cdot \log(1-p)]$

3 Retropropagación

Cuánto aportó cada peso al error

4 Descenso del gradiente (Adam)

Ajusta cada peso un poco

Lote: 32 correos

→ 364 actualizaciones por época

Época: máximo 6

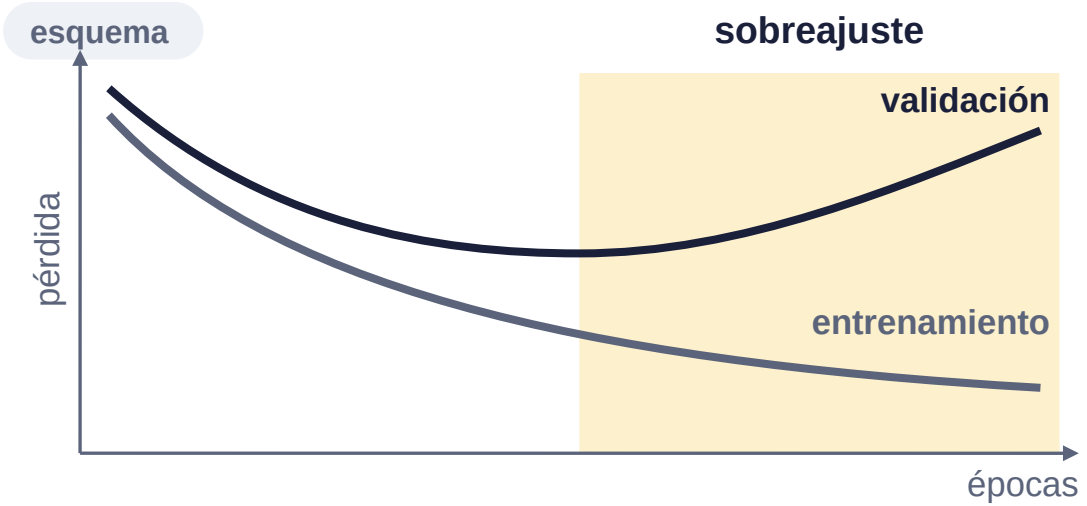
Una pasada por los 11.629 correos de entrenamiento

Ejemplo de pérdida

Fraude con *p* = 0,9 → pérdida **0,11**

Fraude con *p* = 0,1 → pérdida **2,30**

Sobreajuste y métricas



		Predicción: Fraude	Predicción: Seguro
Real	Fraude	Fraude detectado (VP)	Fraude que se escapa (FN): **el error caro**
Real	Seguro	Falsa alarma (FP)	Seguro bien clasificado (VN)

- **Dropout** 0,5
- **Validación separada:** 2.053 correos
- **Parada temprana:** paciencia 2

Recall: de los fraudes, cuántos detecta

Precisión: de los marcados, cuántos eran fraude

AUC: qué tan bien separa (1 perfecto, 0,5 azar)

Decir siempre “seguro” ya acierta 6 de cada 10: **la exactitud sola engaña**

Lo que entrega el modelo



El umbral lo decide la organización: más bajo detecta más fraude, con más falsas alarmas

Ahora: implementación en vivo

[Nombre estudiante 2]